Multi Expert Peptide Pipeline

Projet de fin d'études

Nathan Fitger Eduard Iliescu Arthur Macdonald Niels Roudeau

Supervisé par : Johan Samot (UB), Enzo Edderbah (ISM) et Akka Zemmari (UB/LABRI)

Université de Bordeaux
Master 2 Informatique — Intelligence Artificielle

Année 2025—2026



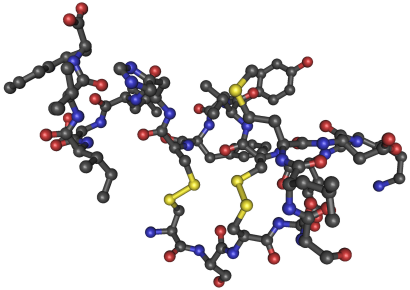
Plan de la présentation

1. Contexte et objectifs
2. Experts et Architecture
   - Expert Générateur de peptides
   - Expert Chimiste
   - Expert Biologiste
   - Architecture du pipeline multi-expert
3. Interface utilisateur
4. Résultats et évaluation du pipeline
5. Discussion et perspectives

Contexte et Objectifs

Pipeline agentique multi expert pour la découverte de peptides *in silico*

in silico: réalisé par ordinateur, sans expérimentation physique.



Peptide

- Chaîne composée d'au plus 50 acides aminés
- 20 acides aminés différents (A,C,D,E,F,G,H,I,K,L,M,N,P,Q,R,S,T,V,W,Y)
- Exprimé sous forme de séquence de lettres (ex: ACEFHKLMNPQY)
- Sujet initial: bactéries dentaires (ex: Streptococcus mutans)

Processus de découverte actuel

- Découverte de peptides: criblage de bibliothèques, évolution dirigée
- Propriétés à optimiser: activité biologique, stabilité, solubilité, etc.
- Évaluation: tests biologiques, simulations moléculaires
- Itération sur les resultats pour améliorer l'efficacité de la peptides
- Coût élevé, temps long, taux de succès faible

Pipeline



Définition et rôle

Une chaîne d'étapes où la sortie d'un module devient l'entrée du suivant, permettant ainsi de répartir des tâches à différents experts.

Générateur

Modèle du générateur

- Modèle générant des séquences de peptides à partir de séquence ou propriétés souhaitées
- Entraîné *from scratch* sur une base de données de peptides connus et leurs propriétés
- Capable de générer des peptides avec des propriétés spécifiques (ex: propriétés chimiques)

Modèles implémentés

- VAE (Variational Autoencoder): apprend une représentation latente des peptides et génère de nouvelles séquences à partir de cette représentation
- CVAE (Conditional Variational Autoencoder): extension du VAE qui conditionne la génération sur des propriétés spécifiques (propritétés physico-chimiques, activité biologique)

Résultats du générateur

VAE et CVAE

- Génération de peptides aléatoires à l'aide du VAE, au format code peptidique (N-terminal vers C-terminal).

ex: IWIGRK

- Génération de peptides à partir de trois propriétés différentes (longueur, cathionicity, hydrophobicity) à l'aide du CVAE

01: KRACLIRRLR

Lettre	Composition chimique
K	Lysine (K)
R	Arginine (R)
A	Alanine (A)
C	Cysteine (C)
L	Leucine (L)
I	Isoleucine (I)

Évaluation du générateur

- Évaluation de la qualité des peptides générés en comparant leurs propriétés à celles des peptides connus

Lorsqu'on donne la sequence KLFKRWKHLFR (peptide connu), une taille 11 et des propriétés physico-chimiques au CVAE, il génère la sequence RKLKLFFRLLR avec des propriétés similaires (selon nos agents).

- Utilisation de métriques telles que la diversité et la validité

Chimiste

Modèle du chimiste

- Entrée: une ou des séquences de peptides (Format code peptidique).
- Configuration: intervalles et cibles des propriétés chimiques souhaitées
- Utilise des règles chimiques et physiques pour donner un score à la peptide à partir des intervalles et cibles séléctionnés

Propriétés chimiques évaluées

Taille de la séquence, Poids moléculaire, Charge nette, LogP (coefficient de partage octanol-eau), Hydrophobicité, Point isoélectrique...

Résultats du chimiste

- Propriétées chimiques de la ou les peptides évalués (Poids moléculaire = 530, LogP = -0.5, ...)
- Score basé sur la distance entre propriété et cible souhaité ou présence dans l'intervale.
- Présence ou non dans les intervalles de propriétés souhaitées.

Biologiste

Modèle du biologiste

- Modèle d'embedding ESM-2 $\rightarrow$ représente les peptides et leurs propriétés biologiques dans un espace latent
- Modèle **esm2_t12_35M_UR50D** par Facebook AI Research, entraîné sur une grande base de données de séquences protéiques (35M de paramètres).
- Basé sur des données biologiques afin d'apprendre les relations entre la structure des peptides et l'activitée biologique

Architecture du pipeline multi-expert

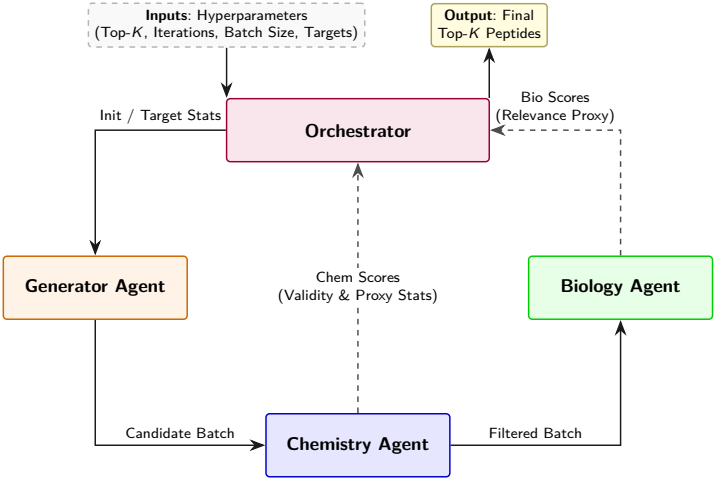
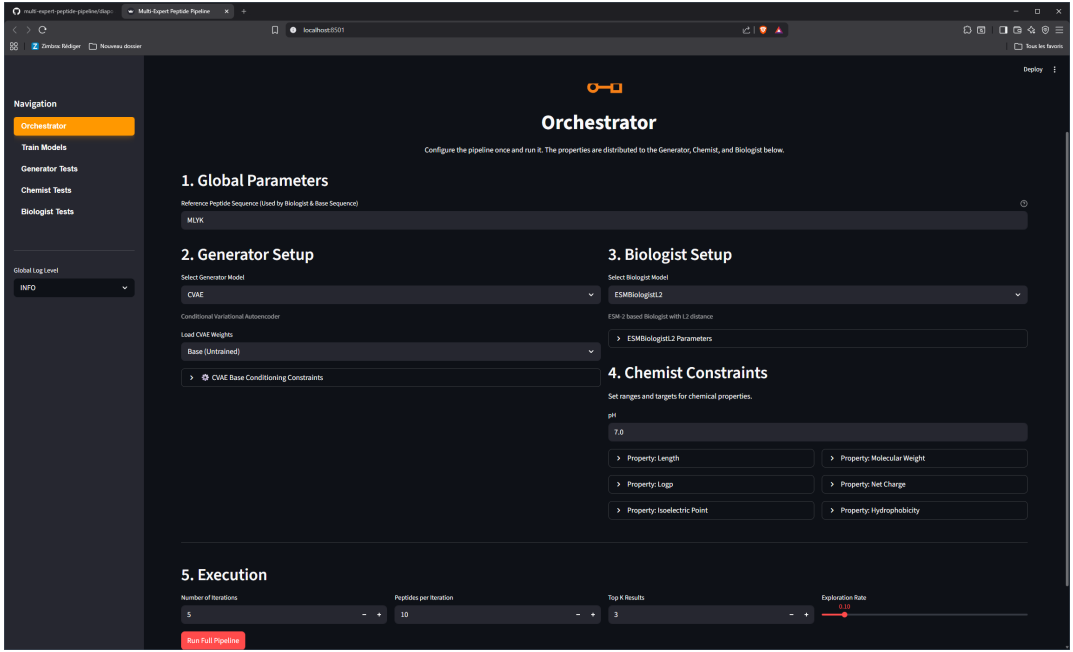
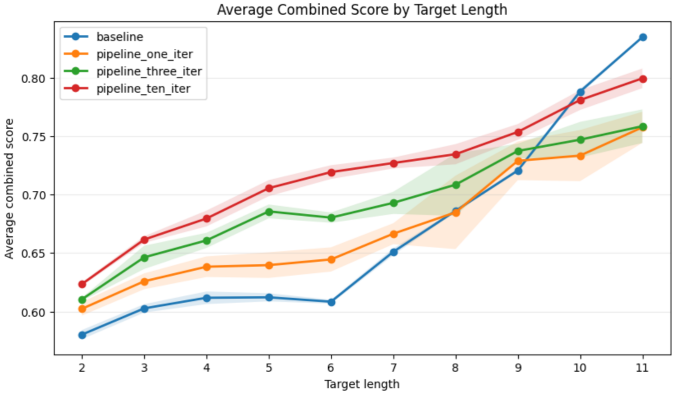


Figure: Agentic Pipeline Architecture.

Interface Graphique



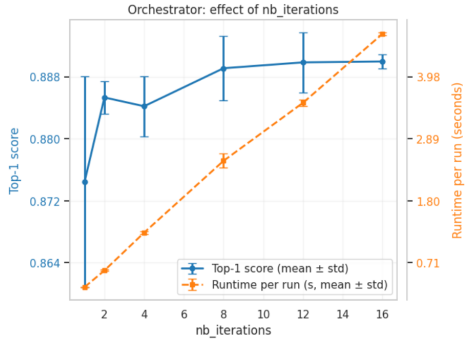
Pipeline vs Baseline

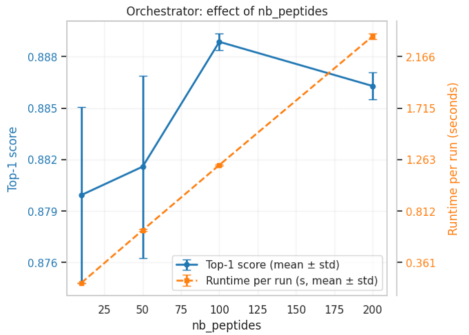


Analyse

- Sur cibles courtes (difficiles), l'itération aide clairement
- Sur cibles longues (faciles), le gain n'est pas systématique
- Plus stable avec plus d'itérations

Etudes d'itérations et de batch



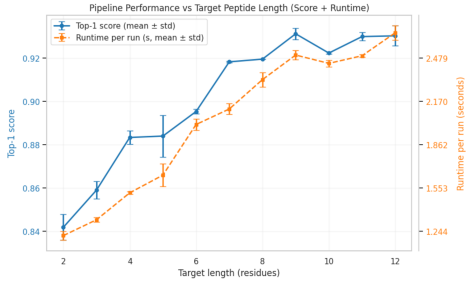


Analyse

Augmenter le budget de recherche améliore très légèrement la qualité mais rapidement le runtime, suggérant une possibilitée d'amélioration d'orchestrateur.

Runtime: RTX 4070 (Portable), Ryzen 7350XT, 16Go RAM

Impact de la longueur cible



Analyse

- Les cibles très courtes (2–3) restent les plus difficiles.
- Le score remonte ensuite jusqu'à un plateau vers la longueur 11.

Attention

Les scores élevés sur des longueurs pathologiques très courtes peuvent refléter une faiblesse de l'expert biologique plus qu'une plausibilité biologique réelle.

Runtime: RTX 4070 (Portable), Ryzen 7350XT, 16Go RAM

Discussion

Portée des résultats

Le pipeline est un **PoC in silico**: les signaux chimie/biologie guident l'optimisation, mais ne remplacent pas une validation expérimentale. Les résultats sont des preuves d'ingénierie et des pistes d'amélioration, pas des conclusions biologiques définitives.

Limites techniques principales

- Contrôle conditionnel dépendant de la **qualité des labels** et des variables de conditioning fournis lors de l'entraînement.
- Signal biologique (ESM): bon proxy d'ordre mais **pas une vérité expérimentale**, risque d'incertitude.
- Orchestrateur: gains marginaux en qualité pour budgets élevés, signe d'une efficacité d'échantillonnage perfectible.

Perspectives

- **Biologiste peptide-spécifique**: entraînement/fine-tuning sur jeux de données peptide-annotés pour produire un score plus discriminatif (activité et risques séparés).
- **Orchestrateur exploration-aware**: politiques adaptatives (exploration dynamique, sélection par incertitude/diversité) pour améliorer rendement qualité/compute.
- **Interface plus expressive**: LLM comme couche d'interface pour traduire objectifs utilisateurs (langage naturel) en contraintes structurées.
- **Chimie enrichie**: ajouter des descripteurs dérivés (SMILES, fingerprints) et intégrer évaluations de synthétisabilité.

$\Longrightarrow$ Ces axes ciblent la robustesse du signal, la contrôlabilité du générateur et l'efficacité de l'orchestration.